

CETYS Universidad



Séptimo Semestre

Materia:

Aplicaciones de Minería de Datos

Docente:

Miguel Gonzalez Marquez

Alumno(s):

Vargas Gámez Ximena

Título:

"Muestreo: FoodExpress"

Fecha:

Miércoles 19 de Agosto del 2026

Tabla de Datos:

ID_Pedido	Zona_Ciudad	Transporte	Clima	Tiempo_Entrega (Min)	Calificacion_App	Queja_Soporte
1001	Centro	Moto	Despejado	15	5	No
1002	Suburbio	Auto	Lluvia	48	1	Sí
1003	Centro	Bici	Despejado	22	N/A	No
1004	Centro	Moto	Despejado	12	N/A	No
1005	Periferia	Auto	Lluvia	65	1	Sí
1006	Centro	Bici	Despejado	25	N/A	No
1007	Suburbio	Moto	Despejado	30	N/A	No
1008	Centro	Moto	Despejado	18	4	No
1009	Periferia	Moto	Lluvia	55	1	Sí
1010	Centro	Bici	Despejado	20	N/A	No
1011	Suburbio	Auto	Despejado	35	N/A	No
1012	Centro	Moto	Despejado	14	5	No
1013	Periferia	Auto	Despejado	45	N/A	No
1014	Centro	Bici	Lluvia	40	2	Sí

1015	Suburbio	Moto	Lluvia	50	1	Sí
1016	Centro	Moto	Despejado	16	N/A	No
1017	Periferia	Auto	Lluvia	60	1	Sí
1018	Centro	Moto	Despejado	13	5	No
1019	Suburbio	Bici	Despejado	28	N/A	No
1020	Centro	Moto	Despejado	17	N/A	No

Los Casos a Analizar

Pregunta 1:

- Un desarrollador Junior sugiere que, para que el algoritmo aprenda mejor, la consulta de extracción debería ignorar los campos vacíos usando la lógica WHERE Calificacion_App IS NOT NULL.
- Observen la tabla: ¿Qué característica comparten casi todos los registros que Sí tienen una calificación? ¿Qué sesgo (bias) exacto introducirían al muestreo si aceptan esta propuesta y cómo afectaría las predicciones en producción?

Pregunta 2:

- Supongan que la variable Transporte = Bici representa solo el 3% de los 5 millones de registros en la base de datos real. Si utilizan un Muestreo Aleatorio Simple para extraer su muestra de 10,000 registros, ¿cuál es el peligro algorítmico al que se enfrentan con respecto a las bicicletas?

Pregunta 3:

- Saben por los reportes de operaciones que la variable clave que destruye los tiempos de entrega es el Clima. En la base de datos total, el 85% de los pedidos se hacen en clima "Despejado" y el 15% en clima "Lluvia". Para garantizar que su algoritmo aprenda correctamente a predecir, diseñen una extracción basada en **Muestreo Estratificado**.
- Describan la regla matemática: De su muestra final de 10,000 registros, ¿cuántos registros exactos deben provenir del clima "Despejado", cuántos del clima "Lluvia", y por qué esto es superior a la extracción aleatoria simple?

